



VI Congreso Internacional de
Investigación Interdisciplinar

CARTAGENA DE INDIAS · 28 AL 30 DE OCTUBRE DE 2026

— LHXT26 · ARTÍCULO DE INVESTIGACIÓN

Evaluación de modelos compactos para tutoría de inglés sin conexión: estabilidad y límites de un benchmark RAG

Evaluating Compact Models for Offline English Tutoring: Stability and Limitations of a RAG Benchmark

Fabián Armando Hoyos Cerón · Yeison Javier Muñoz Gómez · Juan José Caiza Narváez

Institución Universitaria Colegio Mayor del Cauca · Grupo I+D Informática · Semillero BETABIT



¿Puede existir tutoría con Inteligencia Artificial donde ni siquiera llega internet?

58.6%

Exclusión por Dependencia de Nube

La dependencia de **conectividad y servicios comerciales** limita el acceso en **más de la mitad** de los hogares rurales.



USB

Ejecución local desde una memoria USB

El sistema se ejecutó desde una **memoria USB** en un **Core i5**, sin GPU ni consultas a servicios en la nube.



0.795

Puntaje similar, alcance limitado

El puntaje semántico original fue **0.795** para ambos modelos, pero no establece equivalencia ni calidad pedagógica.



Ruta de la Presentación

01

Contexto y Problema
Rural

02

Metodología y
Pipeline RAG

03

Resultados y
Hallazgos

04

Discusión y
Conclusiones

FASE 1 DE 4

Contexto y Problema Rural

Brecha de conectividad y necesidad de tutoría local sin internet.

01

Contexto Rural

■ EN CURSO

02

Metodología RAG

03

Resultados

04

Discusión

De la brecha de conectividad a las preguntas que guiaron el benchmark



Fuente: Alcaldía de Cali & MinTIC · tinyurl.com/2dj75zmn

DANE 2024 · BARRERA INFRAESTRUCTURAL

DANE

58.6%

Hogares rurales sin internet en Colombia; hace inviable cualquier modelo dependiente de la nube.

01 · PREGUNTA TECNOLÓGICA



¿Qué permite comparar el puntaje entre dos modelos compactos?

Comparar Phi-4-mini (3.8B) y Qwen2.5-3B (3B) en un Core i5 con 8 GB de RAM, sin tarjeta gráfica.

02 · PREGUNTA METODOLÓGICA



¿Qué mide el evaluador automático?

Examinar los criterios léxico y semántico y su capacidad para diferenciar modelos sin evaluadores remotos.

FASE 2 DE 4

Metodología y Pipeline RAG

Arquitectura local, pipeline híbrido y protocolo de evaluación ciega.

01
Contexto Rural

✓ VISTO

02
Metodología RAG

■ EN CURSO

03
Resultados

04
Discusión

Flujo secuencial del pipeline RAG: de la consulta a la generación




USB
EJECUCIÓN LOCAL

Ejecución local durante la prueba

El pipeline de búsqueda, reordenamiento e inferencia se ejecutó desde USB en el equipo evaluado, sin GPU ni consultas a servicios en la nube.

Demostración técnica: interfaz local y generación sin conexión



PAQUETE AUTOCONTENIDO

- Motor C++ (llama.cpp) precompilado
- Pesos del benchmark (Phi-4-mini / Qwen2.5-3B)
- Índice RAG local + Web UI en localhost

Memoria USB · Entorno portátil sin conexión

Entorno evaluado: Intel Core i5 · 8 GB RAM · SSD SATA · sin GPU

01 · VELOCIDAD OBSERVADA

1.82–1.96 tok/s en Core i5


Medias observadas en el equipo evaluado, sin aceleración gráfica.



02 · TRAZABILIDAD DEL CORPUS

Anclaje de página y fragmento

Cada pregunta se vinculó con páginas del libro y fragmentos recuperados del corpus.




Banco de evaluación: 14 preguntas diseñadas para el aula rural

COMPETENCIA	CÓDIGOS	PÁGINAS	PROPÓSITO PEDAGÓGICO
Grammar	G1 – G4	191 – 235	4 preguntas sobre reglas gramaticales y tiempos verbales.
Vocabulary	V1 – V3	36 – 150	3 preguntas de definición y uso en contexto formal.
Writing	W1 – W3	68 – 138	3 preguntas sobre estructura de párrafos y coherencia.
Reading	R1 – R2	15 – 60	2 preguntas de comprensión e inferencia textual.
 Fuera de alcance	F1 – F2	Sin registro	2 sondas fuera de alcance: Examina respuestas y rechazos cuando no existe respaldo documental.

TOTAL: 14 ÍTEMS DE EVALUACIÓN

12 Curriculares · 2 Sondas de Rechazo



TEXTO GUÍA OFICIAL

College ESL Writers Applied Grammar and Composing Strategies

Autoras: B. Hall & B. Wallace

Institución: University System of Georgia

299 págs · Recurso educativo abierto

01 · CORPUS RAG VECTORIAL

339 Trozos Semánticos


Segmentos de ≤ 512 palabras indexados en el aula offline para recuperación semántica inmediata.



02 · COTEJO DEL CORPUS

Citas Página a Página

Cada pregunta conserva su anclaje de página para verificar el origen en el libro.



LICENCIA ABIERTA

Hall & Wallace · CC BY-NC-SA 3.0

Protocolo comparativo: configuraciones, modelos y variación entre semillas

196 COMBINACIONES BASE ÚNICAS

14 preguntas × 7 esquemas RAG × 2 modelos SLM

140 EJECUCIONES ADICIONALES

cfg_eval_full · 4 semillas y repetición de control

ALCANCE DEL ESTUDIO Laboratorio · sin estudiantes · sin medición de aprendizaje

6

Configuraciones léxicas

top-k: 3 – 10 • Temp: 0.1 – 0.7

Evaluación por coincidencia léxica (Jaccard)



1

Evaluador semántico

cfg_eval_full • Embeddings

Sustituye Jaccard por el criterio semántico



4

Semillas de Réplica

42 · 7 · 123 · 2026

Control estocástico de varianza interna



2

Métricas de Auditoría

Jaccard + criterio semántico

Apego al material, no calidad pedagógica



FASE 3 DE 4

Resultados y Hallazgos

La coincidencia de 0.795, la variación por semillas y el piloto de valoración docente.

01
Contexto Rural

✓ VISTO

02
Metodología RAG

✓ VISTO

03
Resultados

■ EN CURSO

04
Discusión



Anatomía de la fórmula: solo 40% examina semánticamente la respuesta

• 40% Evalúa fidelidad semántica

▼ La consulta, no la respuesta


▼ Solo caracteres

40% GROUNDING (r, c) Único término que evalúa la respuesta generada 	40% RELEVANCE (q, c) Pregunta vs. contexto · ¡Ignora la respuesta! 	20% LONGITUD (r) Conteo de caracteres 
--	---	--

0.00 → 0.50	Coseno Reescalado: $(x + 1)/2$ Un coseno de 0 se transforma en 0.50; el umbral global combina los tres componentes. 	Nota = 0.80	Rama de negativa (9 frases) Nueve frases activan 0.80 constante, fuera del cálculo ordinario del puntaje. 
--------------------	---	---------------------------	--

■ **HALLAZGO CLAVE:** Un puntaje cuantitativo de **Q ≈ 0.80** no certifica calidad pedagógica: la métrica numérica exige auditoría cualitativa en código para detectar distorsiones y abstenciones.

Tras excluir las sondas, 0.8030 vs 0.8010: la variación supera la diferencia entre modelos ($p = 0.569$)



$\rho = -0.273$ / -0.066 **Puntaje y cobertura**

Relación baja entre cfg_eval_full y cobertura de palabras clave en Phi / Qwen (12 preguntas).

0.037 vs 0.025 Ruido Estocástico

Varianza por semilla (**0.037**) supera la diferencia absoluta entre modelos (**0.025**) · 1.5× mayor.

Respuestas sin respaldo y falsos rechazos: patrones distintos con puntajes cercanos

PATRÓN OBSERVADO · $Q = 0.8030$



Phi-4-mini 3.8B


Patrón observado: respondió con mayor frecuencia a sondas sin respaldo.

Rechazo correcto: **28.6%**



Respondió 10 de 14 sondas fuera de alcance.

Falso rechazo: **0.0%**



0 falsos rechazos observados.

PATRÓN OBSERVADO · $Q = 0.8010$



Qwen2.5-3B 3B


Patrón observado: activó más rechazos ante consultas sin respaldo.

Rechazo correcto: **85.7%**



Rechazó 12 de 14 sondas fuera de alcance.


Falso rechazo: **7.1%**



Rechazó 6 consultas con respaldo documental.

HALLAZGO CLAVE: Puntajes próximos no bastan para seleccionar un modelo sin examinar los tipos de fallo.

Valoración docente (n = 10): desacuerdo y baja asociación con el indicador



4 / 10

Coincidencias de Uso

Coincidieron en cuatro decisiones. Cada docente aprobó tres respuestas distintas.

$\kappa = -0.429$

Desacuerdo entre Evaluadores

Kappa de Cohen negativo.

$\rho = +0.137 / +0.259$

Indicador frente a docentes

Asociaciones observadas con T1 y T2, respectivamente (n = 10).

— FASE 4 DE 4

Discusión y Conclusiones

Alcance del evaluador, patrones de fallo y trabajo posterior antes de cualquier despliegue.

01
Contexto Rural

✓ VISTO

02
Metodología RAG

✓ VISTO

03
Resultados

✓ VISTO

04
Discusión

■ EN CURSO

Apego al texto no es aprendizaje: criterios para auditar tutores

01 · EL RIESGO OCULTO

Límite del Promedio

Refleja apego al material, no comprensión ni capacidad pedagógica.

0.795

APEGO AL MATERIAL

02 · EL ESTÁNDAR TÉCNICO

Auditoría Desglosada

No basta un promedio único: informar fidelidad y rechazo por separado.

3

DIMENSIONES

03 · RECHAZOS Y RESPUESTAS SIN RESPALDO

Qwen2.5-3B: Mayor rechazo

Rechazó 12 de 14 sondas sin respaldo y 6 de 84 preguntas con respaldo.

85.7%

RECHAZO DE SONDAS

04 · RECHAZOS Y RESPUESTAS SIN RESPALDO

Phi-4-mini: Menor rechazo

Respondió 10 de 14 sondas sin respaldo documental.

71.4%

RESPUESTAS A SONDAS

Tres observaciones para evaluar tutores de IA sin conexión

01 · FACTIBILIDAD

USB

EJECUCIÓN LOCAL SIN GPU

Factibilidad en el equipo evaluado

En el Core i5 evaluado, Phi alcanzó 1.82 y Qwen 1.96 tok/s, sin GPU.

02 · METODOLOGÍA

4

SEMILLAS OBSERVADAS

Control de Variabilidad Estocástica

La dispersión interna superó la diferencia media. Una sola corrida no basta para ordenar los modelos.

03 · DOCENCIA

$\kappa = -0.429$

VALORACIÓN PILOTO

Rúbrica docente por precisar

Dos docentes discreparon en diez respuestas. El piloto no permite calibrar el indicador ni medir aprendizaje.

APORTE CENTRAL

Aporte del estudio

El procedimiento separa **recuperación, respuesta y evaluación** antes de un posible despliegue.

ALCANCE: 1 libro · 14 preguntas · 4 semillas · 1 equipo · sin estudiantes

Fuentes esenciales del estudio

01 · FUNDAMENTOS Y EVALUACIÓN

Lewis, P., Perez, E., Piktus, A., et al. (2020)

Retrieval-augmented generation for knowledge-intensive NLP tasks. *NeurIPS*, 33, 9459–9474.

Arquitectura RAG fundacional

Hall, B., & Wallace, E. (2018)

College ESL writers: Applied grammar and composing strategies for success. *University System of Georgia*.

Corpus abierto de 299 páginas

Nogueira, R., & Cho, K. (2019)

Passage re-ranking with BERT. *arXiv:1901.04085*.

Re-clasificación cross-encoder para recuperación precisa

02 · MODELOS SLM Y ARTÍCULO BASE

★ ARTÍCULO PREVIO DE ARQUITECTURA · COLMAYOR CAUCA

Muñoz-Gómez, Y. J., Hoyos-Cerón, F. A., & Caiza-Narváez, J. J. (2026)

Design of a portable retrieval-augmented generation architecture for offline intelligent tutoring on resource-constrained hardware. *Entramado*, 22(2), e-13645.

Abouelenin, A., et al. (2025)

Phi-4-Mini technical report: Compact yet powerful multimodal language models via Mixture-of-LoRAs. *arXiv:2503.01743*.

Microsoft Research · 3.8B parámetros

Yang, A., et al. (2024)

Qwen2.5 technical report. *arXiv:2412.15115*.

Alibaba Cloud · 3B parámetros

Gracias por su atención

Evaluación de modelos compactos para tutoría de inglés sin conexión · VI Congreso Internacional Cartagena 2026

RECONOCIMIENTO INSTITUCIONAL

Institución Universitaria Colegio Mayor del Cauca

Grupo de Investigación I+D Informática · Semillero BETABIT

DOCENTES EVALUADORES (EVALUACIÓN A CIEGAS)

Juan Pablo Machado Vélez & Stevens Álvarez Domínguez

Agradecimiento por la valoración piloto independiente y ciega de diez respuestas.

COORGANIZAN:



SESIÓN DE PREGUNTAS · AUDITORIO

Diálogo y Discusión Abierta

Cartagena de Indias · 28 al 30 de octubre de 2026

CORRESPONDENCIA:

fahoyos@unimayor.edu.co

yjmunoz@unimayor.edu.co

juanjosecaiza@unimayor.edu.co



REPOSITORIO DEL ESTUDIO

GitHub · PocketMentorEDU

Datos anonimizados, figuras y scripts de verificación en
reproducibility/lhxt2026.